RAPPORT TECHNIQUE • DATA ENGINEERING

Compte-rendu de Projet : SciPulse & Visualisation Kibana

Auteur : **Biolohf Tchatchoua Tetsa** Date : **19 Octobre 2026** Projet : **SciPulse - Étape 1 Infrastructure**

Volume d'enregistrements ingérés & indexés
Index Elasticsearch : `arxiv-papers-enriched`

50 000

1. Contexte et Objectifs du Projet

Le projet **SciPulse** vise à mettre en place un pipeline de données complet (architecture Medallion : Bronze, Silver, Gold) pour l'ingestion, le traitement et l'analyse de publications scientifiques issues d'ArXiv. L'objectif final était de déployer l'infrastructure complète via des conteneurs Docker, de charger un volume de 50 000 enregistrements enrichis dans Elasticsearch, et de concevoir un tableau de bord analytique sous Kibana répondant aux exigences du cours avant la date limite.

2. Architecture Technique Déployée

L'infrastructure complète a été orchestrée avec succès à l'aide de Docker Compose, regroupant l'ensemble des services nécessaires :

Apache Airflow
`airflow-webserver` & `scheduler` : Gestion et automatisation des workflows et DAGs d'ingestion.

Apache Spark
Master & Worker : Traitement distribué et transformation volumétrique des données.

Elasticsearch
Moteur de recherche et stockage NoSQL indexant les publications scientifiques.

Kibana
Interface de visualisation, d'exploration et de métriques en temps réel.

MinIO & PostgreSQL
Stockage d'objets (S3-compatible) et base de données relationnelle pour la persistance des métadonnées.

3. Réalisations et Étapes Clés

• **Résolution des dépendances et de l'environnement**
Configuration rigoureuse du fichier d'environnement `.env` et correction des permissions de conteneurs (résolution de l'erreur `Errno 13 Permission denied`) pour assurer le bon fonctionnement du planificateur Airflow et la détection effective des DAGs.

• **Ingestion et Validation des Données**
Chargement effectif de 50 000 documents dans l'index Elasticsearch. Création et configuration de la vue de données **ArXiv enrichi** (`arxiv-papers-enriched`) dans Kibana, sans filtre temporel restrictif pour garantir l'accès à l'intégralité du corpus.

• **Conception du Tableau de Bord (Dashboard Kibana)**